Кейс “Самокат”

выполнил: Толстяков Роман

Дизайн исследования

На первом этапе необходимо проверить структуру данных, чтобы выявить особенности в хранении записей, что существенно ускорит процессе решения бизнес кейса. Несмотря на то, что задача реализовать расчеты на Python с использованием библиотек **pandas / numpy / seaborn**, на предварительном этапе воспользуемся SQL. В дальнейшем сравним результаты, а также оценим временные затраты при решении кейса двумя способами:

products.xlsx - загружен в таблицу sam_products
orders.xlsx - загружен в таблицу sam_orders

1) Посмотрим количество записей в каждой таблице

```
SELECT 'orders' AS "table", count(*) AS records
FROM sam_orders
UNION ALL
SELECT 'products' AS "table", count(*) AS records
FROM sam_products
```

В результате получается, что в таблице **orders** записей более чем 10 раз меньше чем в таблице **products**. Это говорит, о том что здесь что-то не нормально, так быть не должно.

table	records
orders	3323
products	40152

2) оценим роль поля product_id

При этом поле product_id по логике первичный ключ. Но так ли это на самом деле. Для этого посчитаем сколько уникальных **product_id** в таблице **Продукты**.

```
SELECT
       count(*) AS records,
       count(DISTINCT p.product_id ) AS cnt_unique_id,
       count (DISTINCT p.name ) AS cnt_products
FROM sam_products p
```

records	cnt_unique_id	cnt_products
40152	40152	13699

Получается что **product_id** уникален, но фактически ссылается не на конкретное наименование продукта, а выступает аналогом нумерации строки. Так как складывается ситуация что происходит дубляж наименований товаров. При этом непонятна природа этих дубляжей. Могут быть разные ситуации начиная от простых ошибок при внесении данных, но эту ситуацию исключаем, закачивая:

- одно и тоже наименование товара в одной и той же категории и подкатегории вносится каждый раз под новым product_id в зависимости от партии закупки. Но тогда у нас нет всех данных чтобы это проверить.
- один и тот же товар судя по наименованию представлен в разных категориях и подкатегориях. Но не в таких же масштабах ?!
- оба варианта

3) структура категорий и подкатегорий

Давайте разберемся со структурой категорий и подкатегорий. Определим количество категорий level1 и количество подкатегорий level2 в каждой категории.

```
SELECT
       sp.level1,
       count( DISTINCT sp.level2 ) AS cnt_level2
FROM sam_products sp
GROUP BY sp.level1
ORDER BY cnt_level2 DESC
```

level1	cnt_level2
Промышленные товары	21
Рынок	14
Уход	12
...	...

Всего 30 категорий **level1** и 168 подкатегорий **level2.** Давайте посмотрим какие товары присутствуют более чем в 1 категории level1 и level2

```
WITH product_cat AS (
       SELECT distinct
              sp.name, sp.level1 ||' \ '||sp.level2  AS level1_2
       FROM  sam_products sp
)
SELECT
       name, count(level1_2) AS cnt_category
```

```
FROM product_cat
GROUP BY name
HAVING count(level1_2) >1
ORDER BY cnt_category desc
```

Всего таких товаров 392, при этом встречаются товары (их больше всего по всем категориям), вообще без названия

name	cnt_category
#VALUE!	57
Картофель	5
Клубника	4
...	...

4) Безымянные товары

Таких товаров не так уж мало - 212 позиций.

```
SELECT count(*)
FROM sam_products sp
WHERE sp.name = '#VALUE!'
```

Итак, мы разобрались как продукты разделяются по категориям и подкатегориям, поняли что одно и то же название может иметь несколько id.

```
SELECT
 name, level1, level2,
 COUNT(name) AS cnt_product_id
FROM sam_products
WHERE name != '#VALUE!'
GROUP BY name, level1, level2
ORDER BY name
```

При этом больше всего бардака в, то есть наличие безымянных товаров, в категориях: *Рынок, Молочная продукция, Кондитерские изделия, Промышленные товары, Кулинария*

```
WITH ranked_ctategory AS (
       SELECT
              level1, count(name) AS cnt_noname,
              DENSE_RANK() OVER (ORDER BY count(name) desc) AS rnk_cat
       FROM sam_products
       WHERE name = '#VALUE!'
       GROUP BY level1
)
SELECT  level1, cnt_noname
```

```
FROM ranked_ctategory
WHERE rnk_cat <= 3
ORDER BY cnt_noname DESC
```

5) Структура таблицы "Заказы"

Если посмотреть на структуру таблицы **sam_orders** можно увидеть как бы ключевое поле order_id, на первой выборке даже складывается ощущение, что это действительно уникальное поле, но по факту это не так. **order_id** - это идентификатор заказа, в который может входить до 30 позиций товаров

```
SELECT so.order_id, count(product_id)
FROM sam_orders so
GROUP BY order_id
ORDER BY count(product_id) DESC
LIMIT 30
```

order_id	count
1517600286	30
1517622334	30
1517552096	27
1517609703	26
...	...

Если рассмотреть один из таких чеков 1517600286 более подробно, то можно увидеть, что в не все product_id из таблицы orders внесены в таблицу product

```
SELECT
       so.product_id,
       sp.level1 ,
       sp.level2 ,
       sp.name AS product,
       round (so.quantity *so.price, 2) AS amount
FROM sam_orders so
LEFT JOIN sam_products sp ON so.product_id  =   sp.product_id
WHERE order_id =1517600286
ORDER BY sp.level1, sp.level2, amount
```

После изучения специфики данных, можно приступать к решению заданий кейса. Предварительные выводы:

- в таблице Продукты присутствуют продукты без названия, но привязанные к конкретным категориям и подкатегориям

- продукт одним и тем же названием может иметь различные product_id, может находиться в разных подкатегориях и категориях
- в таблице продукты отражены не все продукты (есть product_id в Заказах, которых нет в Продуктах)

Решение кейса SQL

Сначала, как и в случае базового анализа данных, реализуем все на SQL

Задача 1.

```
SELECT
       coalesce (p.level1,'!!! Категория отсутствует') AS category,
       sum(o.quantity) AS total_sale,
       count (DISTINCT o.order_id) AS cnt_orders
FROM sam_orders o LEFT JOIN sam_products p ON o.product_id =p.product_id
GROUP BY p.level1
ORDER BY total_sale  DESC
```

Выводы:

В Топ 3 категорий входит “безымянная категория”, то есть продукты, не имеющие соответствующей записи в таблице Продукты продавались в 197 заказах на суммарное количество 373 штуки

Категория	**Продано, шт**	**кол-во заказов**
Безалкогольные напитки	534	218
Молочная продукция	483	211
!!! Категория отсутствует	373	197
Свежие овощи	262	145

Самые слабые по продажам категории: Рыба, Детство (Гигиена и Уход), Специальное питание

Категория	**Продано, шт**	**кол-во заказов**
Рыба	8	7
Детство (Гигиена и Уход)	6	6
Специальное питание	2	1

Задача 2.

```
WITH marked_category AS (
       SELECT
              p.level1,
              sum(o.quantity) AS total_sale
       FROM sam_orders o JOIN sam_products p ON o.product_id =p.product_id
       GROUP BY p.level1
)
SELECT
       p.level1,
       p.level2,
       sum(o.quantity) AS total_sale
FROM sam_orders o JOIN sam_products p ON o.product_id =p.product_id
JOIN marked_category mc ON mc.level1 = p.level1
GROUP BY p.level1, p.level2, mc.total_sale
ORDER BY mc.total_sale DESC,  total_sale DESC
```

Выводы:

Самые лучшие по продажам категории: Безалкогольные напитки, Молочная продукция,Свежие овощи

Но при этом лучшие подкатегории только в одном случае совпадают с категориями:

Категория	**Подкатегория**	**Продано, шт.**
Безалкогольные напитки	Напитки	252
Кулинария	Готовые блюда	248
Хлеб и хлебобулочные изделия	Хлеб и хлебобулочные изделия	218
Снэки	Снэки соленые	180
Безалкогольные напитки	Воды питьевые	162
Свежие овощи	Корнеплоды, зелень и прочие овощи	157
Молочная продукция	Молоко и сливки	147
Молочная продукция	Молочно-десертные продукты	116
Свежие фрукты	Цитрусовые, семечковые и прочие плоды	108
Молочная продукция	Кисломолочные традиционные продукты	106

То есть по суммарным показателям категория “Молочная продукция” вторая по рейтингу, но самая лучшая подкатегория “Молоко и сливки” данной категории на 5 месте. Это говорит о том, что детализированный анализ целесообразно проводить именно по подкатегориям.

Задача 3

```
SELECT round(sum(price * quantity) / count(DISTINCT order_id),2) avg_chek
FROM sam_orders
WHERE accepted_at::date = '2022-01-13'
```

Выводы:

Тут все просто стредний чек за эту дату = `915.64`
Для более детального анализа можно сравнить продажи по месяцам, сравнить насколько “старый новый год” по среднему чеку отличается от других дней нвогодних праздников и сделать выводы

Задача 4

```
SELECT
       sum(CASE WHEN o.price = o.regular_price  THEN o.quantity END) AS normal,
       sum(CASE WHEN o.price != o.regular_price THEN o.quantity END) AS promo
FROM sam_orders o
JOIN sam_products p ON o.product_id =p.product_id
WHERE p.level1 = 'Сыры'
```

Масштабируем на все категории:

```
SELECT
       p.level1 AS category,
       round(COALESCE (sum(CASE WHEN o.price = o.regular_price  THEN o.quantity
END)*100.0 / sum(o.quantity),0),1) AS normal,
       round(COALESCE (sum(CASE WHEN o.price != o.regular_price THEN o.quantity
END)*100.0 / sum(o.quantity),0),1) AS promo
FROM sam_orders o
JOIN sam_products p ON o.product_id =p.product_id
GROUP BY p.level1
ORDER BY promo desc
```

Выводы:

Доля промо продаж в категории “Сыры” составляет 30,7%
среди всех категорий по доле промо продаж “Сыры” занимают 16 место, уступая
Детство (Гигиена и Уход) 33,3%;
Кофе, какао 33,3%;
Замороженная продукция 33,7%

Задача 5

```
SELECT
       level1 AS category,
       sum((price-cost_price)*quantity) AS margin_abs,
       round(sum((price-cost_price)*quantity)*100.0 / sum(price*quantity),2)  AS
margin_pct
FROM sam_orders o
JOIN sam_products p ON o.product_id =p.product_id
GROUP BY level1
ORDER BY margin_abs desc
```

Выводы:

Выделены топ 3 категории по маржинальности, примечательно, что безусловным лидером и по продажам, и по количеству проданных товаров, и по маржинальности остаются безалкогольные напитки. А вот “Кулинария” и “Замороженная продукция” по маржинальности в ТОПе, а по количественным характеристикам нет.

category	margin_abs	margin_pct
Безалкогольные напитки	**20373**	**44.19**
Кулинария	**18452**	**45.18**
Замороженная продукция	**13099**	**47.26**
Молочная продукция	12493	33.24
Мясная гастрономия	10230	42.36
Снэки	9582	42.63
Свежие овощи	9006	27.11
Бакалея	8177	37.57
Свежие фрукты	7879	29.17
Сыры	7474	37.70
Мучные кондитерские изделия	6283	45.19
Хлеб и хлебобулочные изделия	6251	42.45
Кондитерские изделия	5918	42.45
Птица	5153	23.06
Кофе, какао	5059	51.83

category	margin_abs	margin_pct
Консервированные продукты	4154	41.12
Гигиена	2971	29.55
Чай	2929	45.67
Рыбная гастрономия	2765	35.03
Мясо	2150	26.70
Детское питание	1817	35.69
Бытовая химия	1441	26.31
Продукция для животных	1113	26.77
Уход	1099	26.33
Рыба	1021	29.51
Яичные товары	781	17.67
Детство (Гигиена и Уход)	517	29.90
Специальное питание	208	50.73

Задача 6

```
-- ABC
WITH sales AS (
       SELECT
              level2,
              sum(quantity) AS sum_quantity,
              sum(price*quantity) AS amount
       FROM sam_orders o JOIN sam_products p ON o.product_id =p.product_id
       GROUP BY level2
       ORDER BY sum_quantity desc
),
abs_quant AS (
       SELECT
              level2 AS sub_category,
              CASE
                     WHEN sum(sum_quantity) over(ORDER BY sum_quantity desc)/
sum(sum_quantity) over() <0.85
                     THEN 'A'
                     WHEN sum(sum_quantity) over(ORDER BY sum_quantity desc)/
```

```
sum(sum_quantity) over() <0.95
                    THEN 'B'
                    ELSE 'C'
             END AS ABC_quantity
       FROM sales
       ORDER BY  ABC_quantity
),
abs_sum AS (
       SELECT
             level2 AS sub_category,
             CASE
                    WHEN sum(amount) over(ORDER BY amount desc)/ sum(amount)
over() <0.85
                    THEN 'A'
                    WHEN sum(amount) over(ORDER BY amount desc)/ sum(amount)
over() <0.95
                    THEN 'B'
                    ELSE 'C'
             END AS ABC_summa
       FROM sales
       ORDER BY  ABC_summa
)
SELECT
 abs_quant.sub_category,
 ABC_quantity,
 ABC_summa
FROM abs_quant JOIN abs_sum ON abs_quant.sub_category = abs_sum.sub_category
ORDER BY ABC_quantity,  ABC_summa
```

Выводы:

sub_category	ABC quantity	ABC summa
Готовые блюда	A	A
Напитки	A	A
Хлеб и хлебобулочные изделия	A	A
Снэки соленые	A	A
Воды питьевые	A	A
Корнеплоды, зелень и прочие овощи	A	A
Молоко и сливки	A	A
Молочно-десертные продукты	A	A

sub_category	ABC quantity	ABC summa
Цитрусовые, семечковые и прочие плоды	A	A
Кисломолочные традиционные продукты	A	A

На основе такой таблицы делать выводы проблематично, но целесообразно подсчитать количество товаров в каждой из групп подкатегорий. Однозначно товары AA - требуют пристального внимания с точки зрения логистики и маркетинга, а вот от товаров CC целесообразно избавится в первую очередь, когда речь зайдет об оптимизации товарного ассортимента.

Для этого перепишем финальный запрос к CTE

```
SELECT
 ABC_quantity ||'/' || ABC_summa AS ABC_cat,
 COUNT (abs_quant.sub_category)
FROM abs_quant JOIN abs_sum ON abs_quant.sub_category = abs_sum.sub_category
GROUP BY ABC_quantity ||'/' || ABC_summa
ORDER BY ABC_cat
```

ABC_cat	count
A/A	29
A/B	5
A/C	3
B/A	8
B/B	10
B/C	2
C/A	1
C/B	9
C/C	33

Реализация на Python

ключевые выводы

Время работы

```
Время выполнения при работе с внешней БД (с подключением): 2.0225 секунд
Время выполнения при работе с внешней БД (без подключения): 1.1633 секунд

Время создания и импорта таблиц  DuckDB: 0.2938 секунд
Время выполнения при работе с DuckDB: 0.0682 секунд
```

Внешняя БД проигрывает DuckDB (даже с учетом импорта данных более чем в 2 раза

Результаты идентичны, за исключением сортировки отдельных полей с одинаковыми признаками сортировки

```
# Сравнение результатов
diff1 = df_Duck_task01.compare(df_DB_task01)
diff2 = df_Duck_task02.compare(df_DB_task02)
diff3 = df_Duck_task03.compare(df_DB_task03)
diff4 = df_Duck_task04.compare(df_DB_task04)
diff5 = df_Duck_task05.compare(df_DB_task05)
diff6 = df_Duck_task06.compare(df_DB_task06)
```

Реализация в чистом питоне без SQL фишек показала не лучший результат по времени:

```
Время выполнения при работе с Pandas only: 2.0473 секунд
```

Исходя из чего, делаю для себя вывод что DuckDB - рулит, по крайней мере на вот таких локальных задачах. Аналогичный вывод сделал Deep Seek.

```
Вывод: Pandas значительно не быстрее внешней PostgreSQL (2.04 с против 2.02 с - примерно одинаково), но сильно уступает DuckDB. Причина - pandas работает со строчными данными в памяти, не оптимизирован для сложных группировок и оконных функций, а также требует ручной реализации многих операций (кумулятивные суммы для ABC-анализа). DuckDB выполняет те же вычисления на порядок быстрее за счёт внутренней оптимизации запросов.
```

Справедливости ради стоит отметить, что метод касательных для ABC анализа в SQL реализовать проблематично, здесь у “чистого Питона” преимуществ, конечно больше.

Так как индексы в массивах не совпадают, при идентичном наборе данных, то сравнение результата проведем следующим образом:

```
set_duck = set(df_Duck_task01[['category', 'total_sale',
'cnt_orders']].itertuples(index=False))
set_python = set(df_Python_task01[['category', 'total_sale',
'cnt_orders']].itertuples(index=False))
```

```
print(set_duck == set_python)
```

Визуализация данных

Единая палитра (с вариантами для всех графиков), минимализм, акцент только на важных моментах - лидеры, аутсайдеры

Задача 1

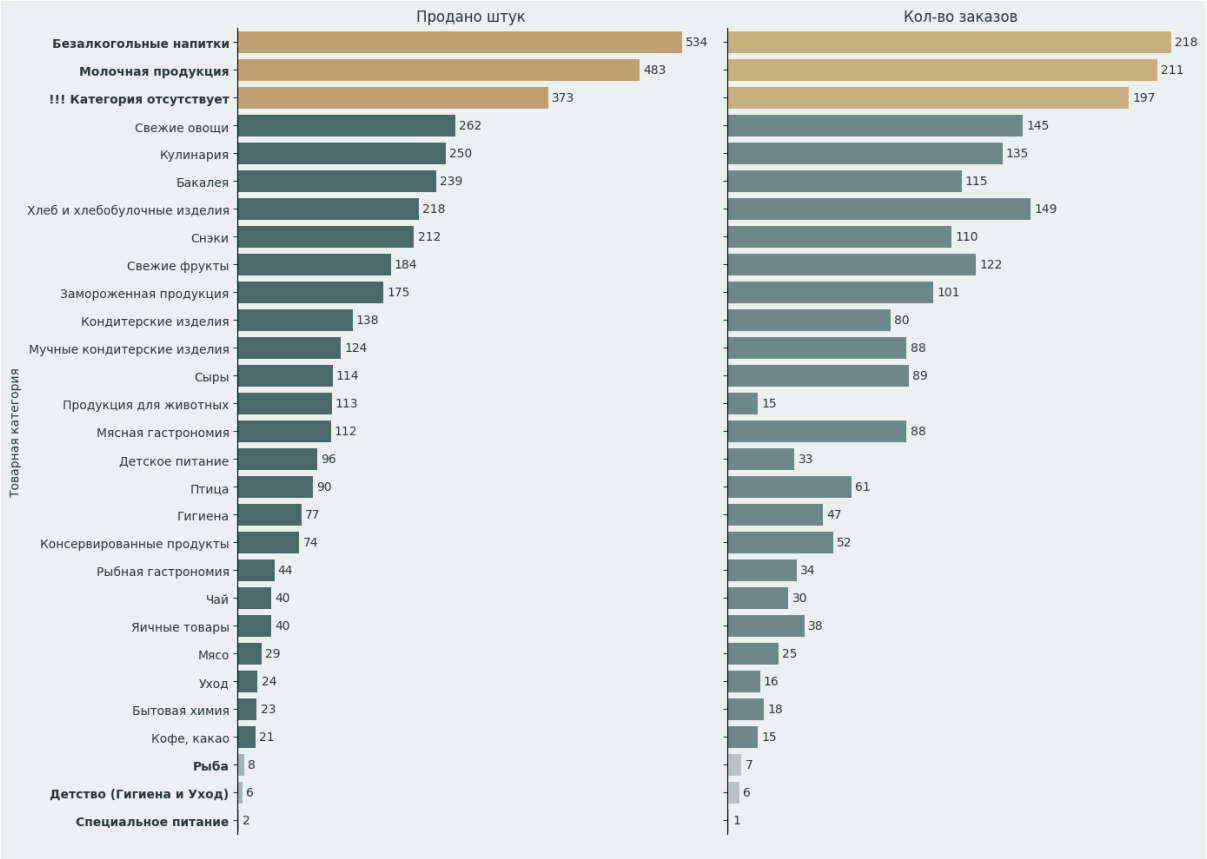

Задача 2

все равно некрасиво, какое-то отрицание пока такой визуализации для отчетов.

Категория	Подкатегория	Продано штук
Безалкогольные напитки	Напитки	252.0
Безалкогольные напитки	Воды питьевые	162.0
Безалкогольные напитки	Соковая продукция	82.0
Безалкогольные напитки	Воды минеральные	38.0
Молочная продукция	Молоко и сливки	147.0
Молочная продукция	Молочно-десертные продукты	116.0

Или так `display(df_Duck_task02)`

	level1	level2	total_sale
0	Безалкогольные напитки	Напитки	252.0
1	Безалкогольные напитки	Воды питьевые	162.0
2	Безалкогольные напитки	Соковая продукция	82.0
3	Безалкогольные напитки	Воды минеральные	38.0
4	Молочная продукция	Молоко и сливки	147.0

Задача 3

Карточка среднего чека

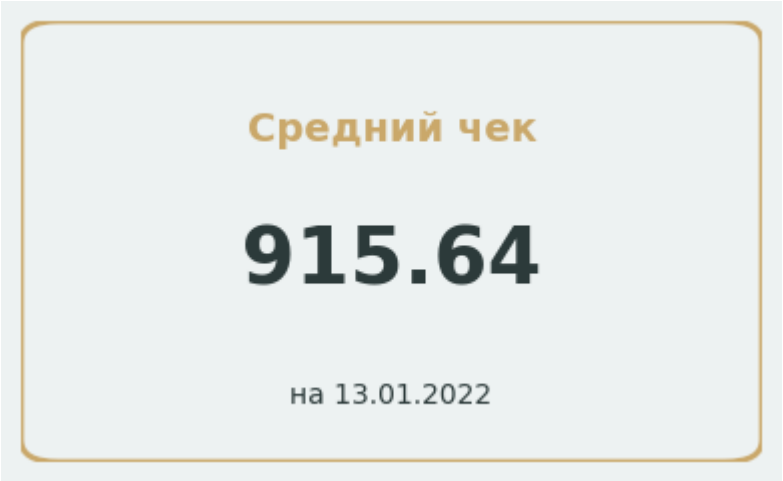

Задача 4

Распределение промо и нормальных продуктов

Задача 5

полный аналог 2 Задачи, хотя здесь логичнее делать разными графиками потому что абсолютная и относительная маржа по ранжированию не совпадают.

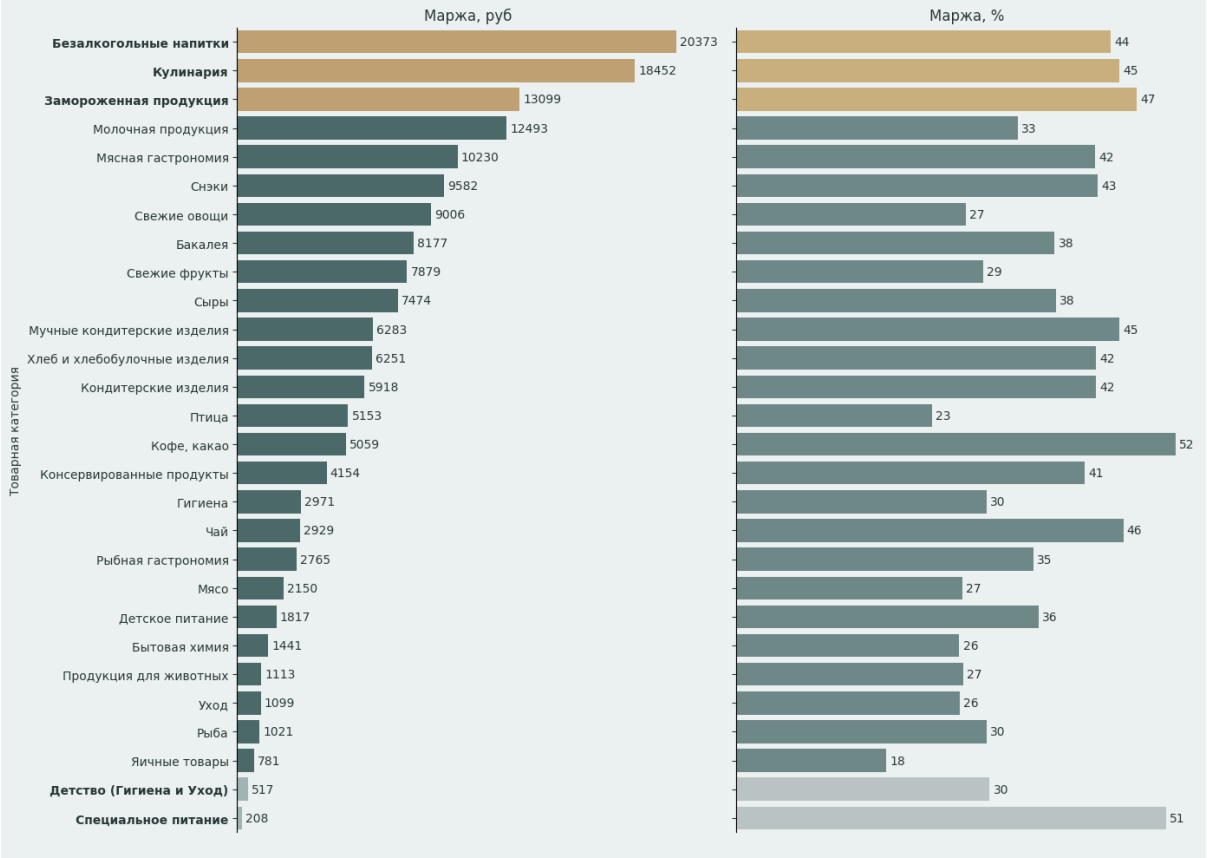

Хотя из этого графика явно видно, что Кофе и какао однозначно надо поднимать по продажам, т.к. наценка высокая, а продажи низкие

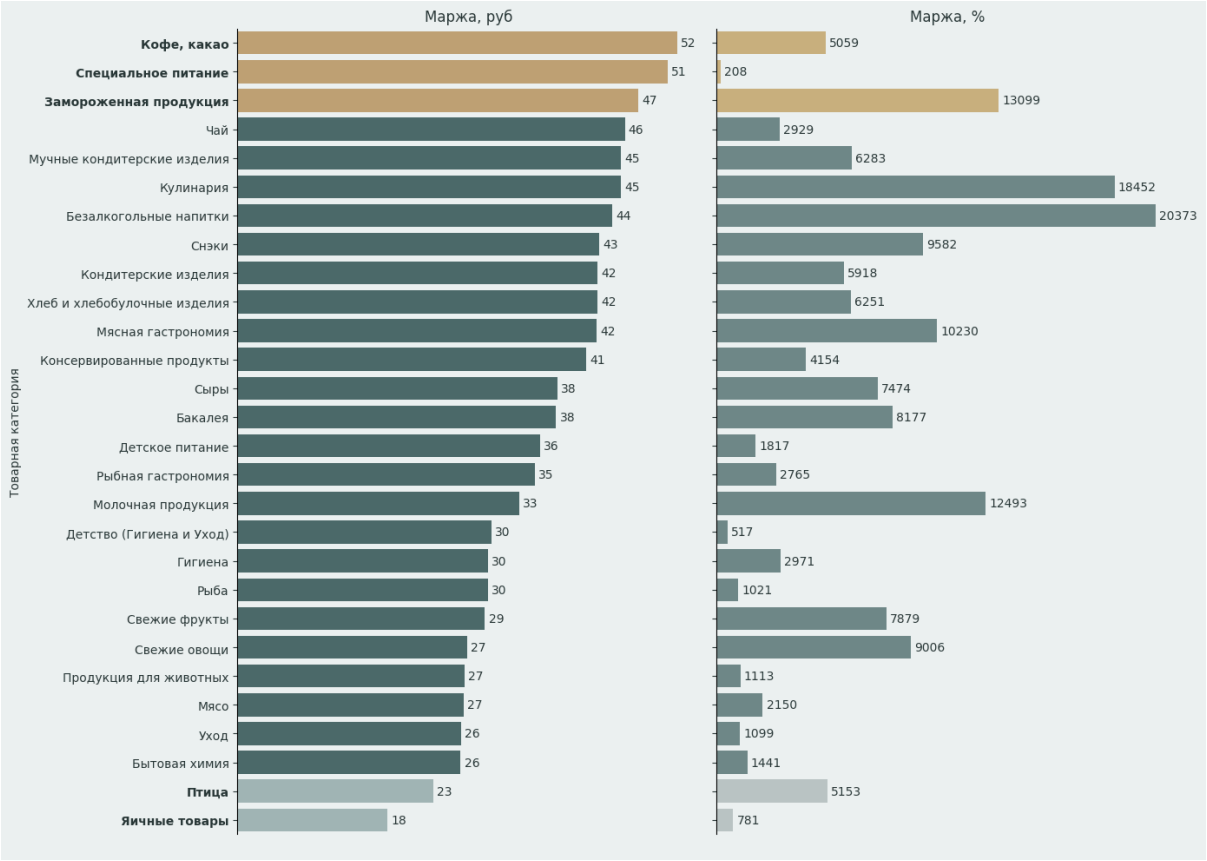
Маржа, руб
Маржа, %
Товарная категория
Кофе, какао 52 5059
Специальное питание 51 208
Замороженная продукция 47 13099
Чай 46 2929
Мучные кондитерские изделия 45 6283
Кулинария 45 18452
Безалкогольные напитки 44 20373
Снэки 43 9582
Кондитерские изделия 42 5918
Хлеб и хлебобулочные изделия 42 6251
Мясная гастрономия 42 10230
Консервированные продукты 41 4154
Сыры 38 7474
Бакалея 38 8177
Детское питание 36 1817
Рыбная гастрономия 35 2765
Молочная продукция 33 12493
Детство (Гигиена и Уход) 30 517
Гигиена 30 2971
Рыба 30 1021
Свежие фрукты 29 7879
Свежие овощи 27 9006
Продукция для животных 27 1113
Мясо 27 2150
Уход 26 1099
Бытовая химия 26 1441
Птица 23 5153
Яичные товары 18 781

Задача 6

ABC-анализ

	Подкатегория	ABC (кол-во)	ABC (выручка)	Итоговая группа
0	Напитки	A	A	AA
1	Готовые блюда	A	A	AA
2	Хлеб и хлебобулочные изделия	A	A	AA
3	Снэки соленые	A	A	AA
4	Воды питьевые	A	A	AA
5	Корнеплоды, зелень и прочие овощи	A	A	AA
6	Молоко и сливки	A	A	AA
7	Молочно-десертные продукты	A	A	AA
8	Цитрусовые, семечковые и прочие плоды	A	A	AA
9	Кисломолочные традиционные продукты	A	A	AA